

SVM

线性可分支持向量机	线性可分	硬间隔最大化
线性支持向量机	近似线性可分 ↳ 有异常点, outliers	软间隔最大化
非线性支持向量机	线性不可分	利用核函数在特征空间隐式学习线性支持向量机

线性可分支持向量机

分离超平面: $w^*x + b^* = 0$

决策函数 $f(x) = \text{sign}(w^*x + b^*)$

一个点到超平面距离的度量

函数间隔 $\gamma^i(w, x^i + b)$

几何间隔 $\frac{\gamma^i(w, x^i + b)}{\|w\|}$

硬间隔最大化 \Rightarrow 几何间隔

定义训练集到超平面的几何间隔

$$\gamma = \min_{i=1,2,\dots,N} \frac{\gamma^i(w, x^i + b)}{\|w\|} \quad (\text{所有点中几何间隔最小的})$$

函数间隔

$$\hat{\gamma} = \min_{i=1,2,\dots,N} \gamma^i(w, x^i + b)$$

定义问题

$$\textcircled{1} \begin{cases} \max_{w,b} v \\ \text{s.t. } \left[\frac{y_i(w x_i + b)}{\|w\|} \geq v \right] \quad i=1,2,\dots,N \end{cases}$$

$$\textcircled{2} \begin{cases} \max_{w,b} \hat{v} \\ \text{s.t. } y_i(w x_i + b) \geq \hat{v} \quad i=1,2,\dots,N \end{cases}$$

$$\textcircled{3} \text{ 取 } \hat{v}=1 \quad \max_{w,b} \frac{1}{\|w\|} \Leftrightarrow \min_{w,b} \frac{1}{2} \|w\|^2$$

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 \\ \text{s.t. } y_i(w x_i + b) \geq 1 \end{cases} \Rightarrow \text{表示的是间隔最大化}$$

有了问题的形式, 接下来是如何求解该问题?
典型的有约束最优化问题, 转化为对偶问题

学习算法

$$\begin{aligned} L(w,b,\alpha) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i (y_i(w x_i + b) - 1) \\ &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w x_i + b) + \sum_{i=1}^N \alpha_i \quad (\alpha_i \geq 0) \end{aligned}$$

$$\max_{\alpha} \min_{w,b} L(w,b,\alpha)$$

$$\text{求解 } \min_{w,b} L(w,b,\alpha)$$

$$\frac{\partial L(w,b,\alpha)}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0$$

$$\frac{\partial L(w,b,\alpha)}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0$$

通过求解 $\min_{w,b} L(w,b,a)$, 得到了

$$w^* = \sum_{i=1}^N a_i y_i x_i$$

$$\sum_{i=1}^N a_i y_i = 0$$

$$\min_{w,b} L(w,b,a) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j x_i \cdot x_j - \sum_{i=1}^N a_i y_i \left(\sum_{j=1}^N a_j y_j (x_i \cdot x_j) + b \right)$$

$$\begin{aligned} &+ \sum_{i=1}^N a_i \\ &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j x_i \cdot x_j - \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j (x_i \cdot x_j) \end{aligned}$$

$$\rightarrow -b \sum_{i=1}^N a_i y_i + \sum_{i=1}^N a_i$$

$$= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N a_i$$

求解 $\max_a (\min_{w,b} L(w,b,a))$

$$\max_a (\min_{w,b} L(w,b,a)) =$$

$$\max_a -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N a_i$$

$$\text{s.t. } \sum_{i=1}^N a_i y_i = 0$$

$$a_i \geq 0$$

通过最优化算法求解上述问题可得最优解 $a^* = (a_1^*, a_2^*, \dots, a_N^*)$
但是我们只知道 w^* 的形式, 代入 a^* 就有了 w^* , 不知道 b^* 的形式, 怎么办?
利用 KKT 条件求解.

回到原问题

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i (\gamma_i (w \cdot x_i + b) - 1) \\ &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i \gamma_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \\ &\quad (\alpha_i \geq 0) \end{aligned}$$

可以列出KKT条件

$$\begin{cases} \nabla_w L(w, b, \alpha) = w^* - \sum_{i=1}^N \alpha_i^* \gamma_i x_i = 0 \\ \nabla_b L(w, b, \alpha) = - \sum_{i=1}^N \alpha_i^* \gamma_i = 0 \\ \alpha_i^* (\gamma_i (w \cdot x_i + b) - 1) = 0 \\ \gamma_i (w \cdot x_i + b) \geq 1 \\ \alpha_i \geq 0 \end{cases}$$

必有 $\alpha_i \geq 0$ (若 α_i 全为 0, 则 $w^* = \sum_{i=1}^N \alpha_i^* \gamma_i x_i = 0$), $\alpha_i \geq 0, \alpha_i \gamma_i (w \cdot x_i + b) - 1 = 0$

$$\begin{aligned} b &= \frac{1}{\gamma_j} - w \cdot x_j \quad \gamma_j = (1, -1) \Rightarrow \frac{1}{\gamma_j} = \gamma_j \\ b &= \gamma_j - w \cdot x_j = \gamma_j - \sum_{i=1}^N \alpha_i^* \gamma_i (x_i \cdot x_j) \end{aligned}$$

至此, 我们得到了线性可分支持向量机的形式. 具体求解算法参照 P123.

注意: 我们可以看到, $\alpha_i \geq 0$, 只有当 $\gamma_i (w \cdot x_i + b) = 1$ 时, 才有 $\alpha_i > 0$.

而 w, b 也就仅仅取决于这些 $\alpha_i > 0$ 的点.

这些 $\alpha_i > 0$ 的点也就是支持向量, w 和 b 仅取决于这些支持向量.

线性支持向量机

如果数据集近似于线性可分, 也就是有些异常点, 那么需要用软间隔最大化.

软间隔最大化

$$\begin{aligned} \text{① } \begin{cases} \max_{w, b, \xi} & \gamma + C \sum_{i=1}^N \xi_i \\ \text{s.t.} & \frac{\gamma_i (w \cdot x_i + b)}{\|w\|} \geq \gamma - \xi_i \end{cases} \end{aligned}$$

\Rightarrow 也就是对于异常点, 我们允许不满足大于 γ 间隔的条件

$$\textcircled{2} \begin{cases} \max_{w,b,\xi} r + C \sum_{i=1}^N \xi_i \end{cases}$$

$$\text{s.t. } \gamma_i(w \cdot x_i + b) \geq r - \|w\| \xi_i$$

$$\hookrightarrow \begin{cases} \max_{w,b,\xi, \|w\|} \frac{r}{\|w\|} + C \sum_{i=1}^N \xi_i \end{cases}$$

$$\text{s.t. } \gamma_i(w \cdot x_i + b) \geq 1 - \|w\| \xi_i$$

取 $r=1$

$$\begin{cases} \max_{w,b,\xi, \|w\|} \frac{1}{\|w\|} + C \sum_{i=1}^N \xi_i \end{cases}$$

$$\text{s.t. } \gamma_i(w \cdot x_i + b) \geq 1 - \|w\| \xi_i$$

$$\hookrightarrow \begin{cases} \min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \end{cases}$$

$$\text{s.t. } \gamma_i(w \cdot x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

分离超平面 $w \cdot x + b = 0$

决策函数 $f(x) = \text{sign}(w \cdot x + b)$

学习算法

$$L(w,b,\xi,\alpha,\mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - \gamma_i(w \cdot x_i + b)] - \sum_{i=1}^N \mu_i \xi_i$$

$$\max_{\alpha,\mu} \min_{w,b,\xi} L(w,b,\xi,\alpha,\mu)$$

求解 $\min_{w,b,\xi} L(w,b,\xi,\alpha,\mu)$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i \gamma_i x_i = 0$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^N \alpha_i \gamma_i = 0 \quad \frac{\partial L}{\partial \xi_i} = C - \alpha_i - \mu_i = 0$$

因此,我们知道

$$W^* = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$C - \alpha_i - \mu_i = 0$$

$$\min_{w, b, \xi} L = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + C \sum_{i=1}^N \xi_i$$

$$+ \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i \xi_i - \sum_{i=1}^N \mu_i \xi_i \rightarrow 0$$

$$- \sum_{i=1}^N \alpha_i y_i \left(\sum_{j=1}^N \alpha_j y_j (x_j \cdot x_i) + b \right)$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i$$

$$= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

与线性可分SVM的形式相同。

$$\max_{\alpha, \mu} \min_{w, b, \xi} L = \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\text{s.t.} \begin{cases} \sum_{i=1}^N \alpha_i y_i = 0 \end{cases}$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0$$

$$\Rightarrow 0 \leq \alpha_i \leq C$$

同样,利用最优化算法求解上述问题,可以得到一个 α^* .

我们仍然只是知道 W^* 的形式, 缺一个 b^* 的形式.

KL条件

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + \left(\sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - \gamma_i (w \cdot x_i + b)] - \sum_{i=1}^N \mu_i \xi_i \right)$$

$$0 \leq \alpha_i \leq C$$

$$\partial_w L = w - \sum_{i=1}^N \alpha_i \gamma_i x_i = 0$$

$$\partial_{\xi} L = C - \alpha_i - \mu_i = 0$$

$$\partial_b L = \sum_{i=1}^N \alpha_i \gamma_i = 0$$

$$\alpha_i [\gamma_i (w^* \cdot x_i + b^*) - 1 + \xi_i^*] = 0$$

$$\mu_i^* \xi_i^* = 0$$

$$\xi_i^* \geq 0$$

$$w^* \cdot x_i + b^* - 1 + \xi_i^* \geq 0$$

$$\text{存在 } 0 < \alpha_i^* < C, \text{ s.t. } \gamma_i (w^* \cdot x_i + b^*) - 1 + \xi_i^* = 0$$

$$\therefore C - \alpha_i^* - \mu_i^* = 0$$

$$1. \mu_i^* \neq 0$$

$$2. \xi_i^* \neq 0$$

$$1. \gamma_i (w^* \cdot x_i + b^*) - 1 = 0$$

$$b^* = \gamma_i - \sum_{j=1}^N \alpha_j^* \gamma_j (x_j \cdot x_i)$$

具体求解法见P129.

$\alpha_i^* = 0$ 2.) $\gamma_i (w^* \cdot x_i + b^*) \geq 1$ 正确分类非支持向量

$0 < \alpha_i^* < C$ 2.) $\gamma_i (w^* \cdot x_i + b^*) = 1$ 正确分类间隔边界上的支持向量

$\alpha_i^* = C$ 2.) $0 < \xi_i^* < 1$ $\gamma_i (w^* \cdot x_i + b^*) < 1$ 正确分类, 间隔边界与超平面之间的支持向量

$$\mu_i^* = 0$$

$$\xi_i^* = | \gamma_i (w^* \cdot x_i + b) | = 0 \quad \text{超平面上}$$

$$[\xi_i^*] \quad \gamma_i (w^* \cdot x_i + b) < 0 \quad \text{分类错误}$$

非线性支持向量机

$$\text{决策函数: } f(w) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* \gamma_i k(x, x_i) + b^* \right)$$

这部分书上的证明很好, 看书吧!

SMO

到此为止, 对于支持向量机, 我们只剩下一个问题没有解决!
那就是如何最优化这个问题?

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j \gamma_i \gamma_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

线性支持向量机, 写成一个极值的形式

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j \gamma_i \gamma_j k(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i \gamma_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

适用线性

和非线性支持向量机。

总结 SMO 算法 (提前注意的有明文的 x_i , 就有明文的 α_i , x_i 与 α_i 是一一对应的)

输入: 训练数据集 $T = \{(x_1, y_1), \dots, (x_N, y_N)\}$, $\gamma \in \{-1, +1\}$, 精度 ϵ
输出: 近似解 α

(1) 初始化 α 为 0,

(2) 对所有的样本点计算 E_i .

$$E_i = \left(\sum_{j=1}^N \alpha_j \gamma_j k(x_j, x_i) + b \right) - \gamma_i$$

(2) 选择 α_1, α_2 单独地优化这两个变量

(1) 首先循环遍历所有满足条件 $0 < \alpha_i < 1$ 的样本点，检验它是否是满足 KKT 条件，取一个不满足 KKT 条件的 α_i 作为 α_1 。

(2) 若所有 $0 < \alpha_i < 1$ 的样本点都满足 KKT 条件，那么遍历所有数据点，取一个不满足 KKT 条件的 α_i 作为 α_1 。

满足 KKT 条件

$$\begin{cases} \alpha_i = 0 \Leftrightarrow y_i g(x_i) \geq 1 \\ 0 < \alpha_i < 1 \Leftrightarrow y_i g(x_i) = 1 \\ \alpha_i = 1 \Leftrightarrow y_i g(x_i) < 1 \end{cases}$$

$$g(x_i) = \sum_{j=1}^N \alpha_j y_j k(x_i, x_j) + b$$

(3) 若 $E_1 > 0$ ，则选择最小的 E_i 作为 E_2 ，相应的 α_i 作为 α_2 。
若 $E_1 < 0$ ，则选择最大的 E_i 作为 E_2 ，相应的 α_i 作为 α_2 。

(4) 计算更新后的 α_1, α_2 即 $\alpha_1^{\text{new}}, \alpha_2^{\text{new}}$

$$\alpha_2^{\text{new,unc}} = \alpha_2^{\text{old}} + \frac{1/2(E_1 - E_2)}{\eta}$$

$$\eta = K_{11} + K_{22} - 2K_{12}$$

$$L = \max(0, \alpha_2^{\text{old}} - \alpha_2^{\text{old}}) \quad 1 - L = \min(1, 1 + \alpha_2^{\text{old}} - \alpha_2^{\text{old}})$$

$$\alpha_2^{\text{new}} = \begin{cases} 1 - L & \alpha_2^{\text{new,unc}} > 1 - L \\ \alpha_2^{\text{new,unc}} & L \leq \alpha_2^{\text{new,unc}} \leq 1 - L \\ L & \alpha_2^{\text{new,unc}} < L \end{cases}$$

$$\alpha_1^{\text{new}} = \alpha_1^{\text{old}} + \gamma_1/2(\alpha_2^{\text{old}} - \alpha_2^{\text{new}})$$

4. 计算 b_{new}

$$b_1^{\text{new}} = -E_1 - \gamma_1 k_{11}(a_1^{\text{new}} - a_1^{\text{old}}) - \gamma_2 k_{21}(a_2^{\text{new}} - a_2^{\text{old}}) + b_1^{\text{old}}$$

$$b_2^{\text{new}} = -E_2 - \gamma_1 k_{12}(a_1^{\text{new}} - a_1^{\text{old}}) - \gamma_2 k_{22}(a_2^{\text{new}} - a_2^{\text{old}}) + b_2^{\text{old}}$$

若 $0 < a_1^{\text{new}} < C$ 且 $0 < a_2^{\text{new}} < C$, $b^{\text{new}} = b_1^{\text{new}}$ 或 $b^{\text{new}} = b_2^{\text{new}}$
其他情况 $b^{\text{new}} = \frac{1}{2}(b_1^{\text{new}} + b_2^{\text{new}})$